



분석 멘토링 C조

7주차

발표자: 김영민

INDEX

001 Deep Learning

- 간단한 손글씨 인식
- 정확도를 높이는 방법
- 깊게 하는 이유

002 여러 CNN 모델

- VGGNet
- GoogLeNet
- ResNet

003 딥러닝의 활용 및 미래


- 딥러닝의 활용
- 딥러닝의 미래

1-1. 간단한 손글씨 인식

DeepLearning

층을 더 깊게 만든 심층 신경망

VGG 기반 CNN



특징

- 3x3 필터 사용
- 층이 깊어지면서 채널 수 증가
16 -> 16 -> 32 -> 32 -> 64 -> 64
- Optimizier = Adam
- Activation Function = ReLU
- Fully Connected 뒤에 Drop Out
- 가중치 초기값 'He의 초기값'
- Pooling으로 공간 크기 줄임

1-1. 손글씨 구현 CNN

```
def __init__(self, input_dim=(1, 28, 28),
             conv_param_1 = {'filter_num':16, 'filter_size':3, 'pad':1, 'stride':1},
             conv_param_2 = {'filter_num':16, 'filter_size':3, 'pad':1, 'stride':1},
             conv_param_3 = {'filter_num':32, 'filter_size':3, 'pad':1, 'stride':1},
             conv_param_4 = {'filter_num':32, 'filter_size':3, 'pad':2, 'stride':1},
             conv_param_5 = {'filter_num':64, 'filter_size':3, 'pad':1, 'stride':1},
             conv_param_6 = {'filter_num':64, 'filter_size':3, 'pad':1, 'stride':1},
             hidden_size=50, output_size=10):
    # 가중치 초기화=====
    # 각 층의 뉴런 하나당 앞 층의 몇 개 뉴런과 연결되는가 (TODO: 자동 계산되게 바꿀 것)
    pre_node_nums = np.array([1*3*3, 16*3*3, 16*3*3, 32*3*3, 32*3*3, 64*3*3, 64*4*4, hidden_size])
    wight_init_scales = np.sqrt(2.0 / pre_node_nums) # ReLU를 사용할 때의 권장 초깃값

    self.params = {}
    pre_channel_num = input_dim[0]
    for idx, conv_param in enumerate([conv_param_1, conv_param_2, conv_param_3, conv_param_4, conv_param_5, conv_param_6]):
        self.params['W' + str(idx+1)] = wight_init_scales[idx] * np.random.randn(conv_param['filter_num'], pre_channel_num, conv_param['filter_size'], conv_param['filter_size'])
        self.params['b' + str(idx+1)] = np.zeros(conv_param['filter_num'])
        pre_channel_num = conv_param['filter_num']
    self.params['W7'] = wight_init_scales[6] * np.random.randn(64*4*4, hidden_size)
    self.params['b7'] = np.zeros(hidden_size)
    self.params['W8'] = wight_init_scales[7] * np.random.randn(hidden_size, output_size)
    self.params['b8'] = np.zeros(output_size)

    # 계층 생성=====
    self.layers = []
    self.layers.append(Convolution(self.params['W1'], self.params['b1'],
                                   conv_param_1['stride'], conv_param_1['pad']))
    self.layers.append(ReLU())
    self.layers.append(Convolution(self.params['W2'], self.params['b2'],
                                   conv_param_2['stride'], conv_param_2['pad']))
    self.layers.append(ReLU())
    self.layers.append(Pooling(pool_h=2, pool_w=2, stride=2))
    self.layers.append(Convolution(self.params['W3'], self.params['b3'],
                                   conv_param_3['stride'], conv_param_3['pad']))
    self.layers.append(ReLU())
    self.layers.append(Convolution(self.params['W4'], self.params['b4'],
                                   conv_param_4['stride'], conv_param_4['pad']))
    self.layers.append(ReLU())
    self.layers.append(Pooling(pool_h=2, pool_w=2, stride=2))
    self.layers.append(Convolution(self.params['W5'], self.params['b5'],
                                   conv_param_5['stride'], conv_param_5['pad']))
    self.layers.append(ReLU())
    self.layers.append(Convolution(self.params['W6'], self.params['b6'],
                                   conv_param_6['stride'], conv_param_6['pad']))
    self.layers.append(ReLU())
    self.layers.append(Pooling(pool_h=2, pool_w=2, stride=2))
    self.layers.append(Affine(self.params['W7'], self.params['b7']))
    self.layers.append(ReLU())
    self.layers.append(Dropout(0.5))
    self.layers.append(Affine(self.params['W8'], self.params['b8']))
    self.layers.append(Dropout(0.5))
```

채널 수 증가, 필터 : 3x3

He initialization

활성화 함수 : ReLU

Pooling으로 공간 줄임

Drop out 사용


1-2. 정확도를 높이는 방법

1. 앙상블 학습

Epoch : 1



Epoch : 2



Epoch : 3



1-3 모델로 예측



2-5 모델로 예측




3-4 모델로 예측

AVG


Final
output

2. 학습률 감소

- Lambda LR



- CosineAnnealingLR



3. 데이터 확장



원본



반전(좌우)



반전(상하)



평행이동



회전




자르기


1-3. 깊게 하는 이유

1. 매개변수 수를 줄일 수 있다.

그림 8-5 5×5 합성곱 연산의 예
입력 데이터




출력 데이터




5×5

5x5 합성곱 연산 : 매개변수 **25**


입력 데이터



중간 데이터



출력 데이터



3×3

3×3

3x3 합성곱 연산 2회 반복 : 매개변수
수(2x3x3) **18**

2. 학습의 효율성 높일 수 있다.

문제를 계층적으로 분해 가능

= 처음 층에서 edge의 패턴을 학습

➡ 풀기 쉬운 문제로 분해 가능

작은 필터를 겹쳐 신경망을 깊게 했을 때 장점

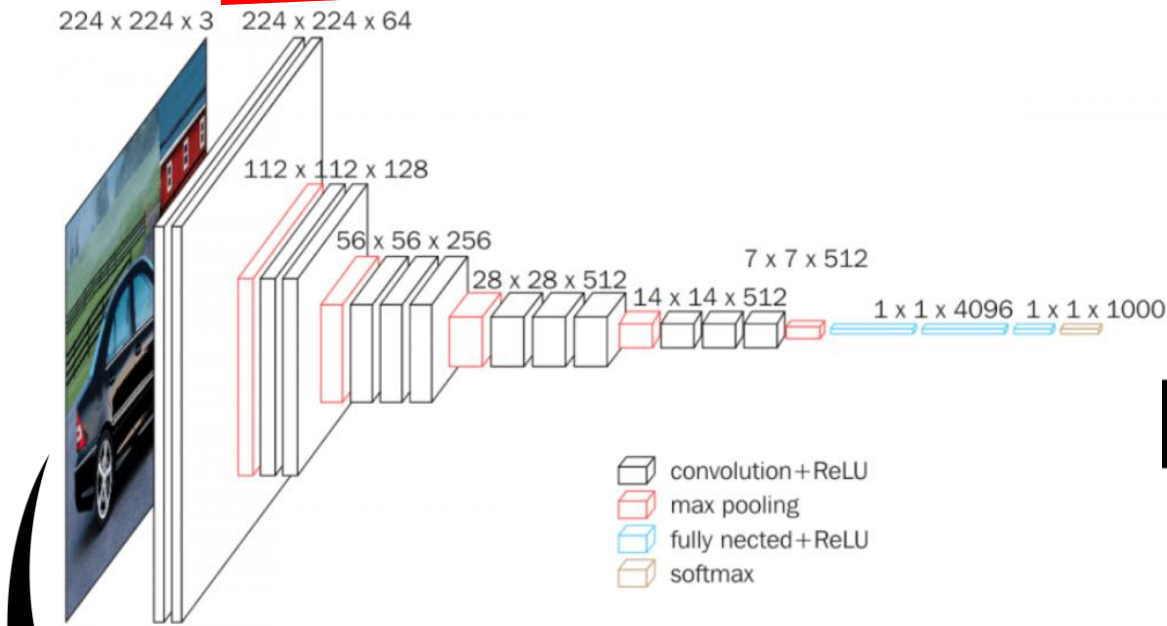
1. 매개 변수 수를 줄여 넓은 수용영역 소화 가능
2. 층을 거듭하며 활성화 함수를 합성곱 사이에 끼워
신경망 표현력 개선

비선형성이 **증가**하여 복잡한 표현도 가능

2. 여러 CNN 모델

2-1. VGGNet

VGG Architecture(VGG16)



Input_size 고정

1층 : 64개의 filter kernel로 input image convolution

4층 : 3x3x128로 convolution
2 x 2 max pooling을 stride 2로 적용해준다.

14층 : 7 x 7 x 512의 feature map flatten
Fully connected, Dropout 적용

16층 : softmax function 적용

3x3 필터 사용 → 파라미터의 개수를 줄여
효율적인 학습을 이뤄냄

Stride = 1 , zero padding,
Activation function = ReLU

2-1. VGGNet

Pytorch로 구현한 VGGNet(Simple version)

```
class VGG(nn.Module):
    def __init__(self, base_dim, num_classes=2):
        super(VGG, self).__init__()
        self.feature = nn.Sequential(
            conv_2_block(3, base_dim),
            conv_2_block(base_dim, 2*base_dim),
            conv_3_block(2*base_dim, 4*base_dim),
            conv_3_block(4*base_dim, 8*base_dim),
            conv_3_block(8*base_dim, 8*base_dim),
        )
        self.fc_layer = nn.Sequential(
            nn.Linear(8*base_dim * 7 * 7, 100),
            nn.ReLU(True), Inplace 연산 실행
            #nn.Dropout(),
            nn.Linear(100, 20),
            nn.ReLU(True),
            #nn.Dropout(),
            nn.Linear(20, num_classes),
        )

    def forward(self, x):
        x = self.feature(x)
        x = x.view(x.size(0), -1)
        x = self.fc_layer(x)
        return x
```

Convolution 연산 2번

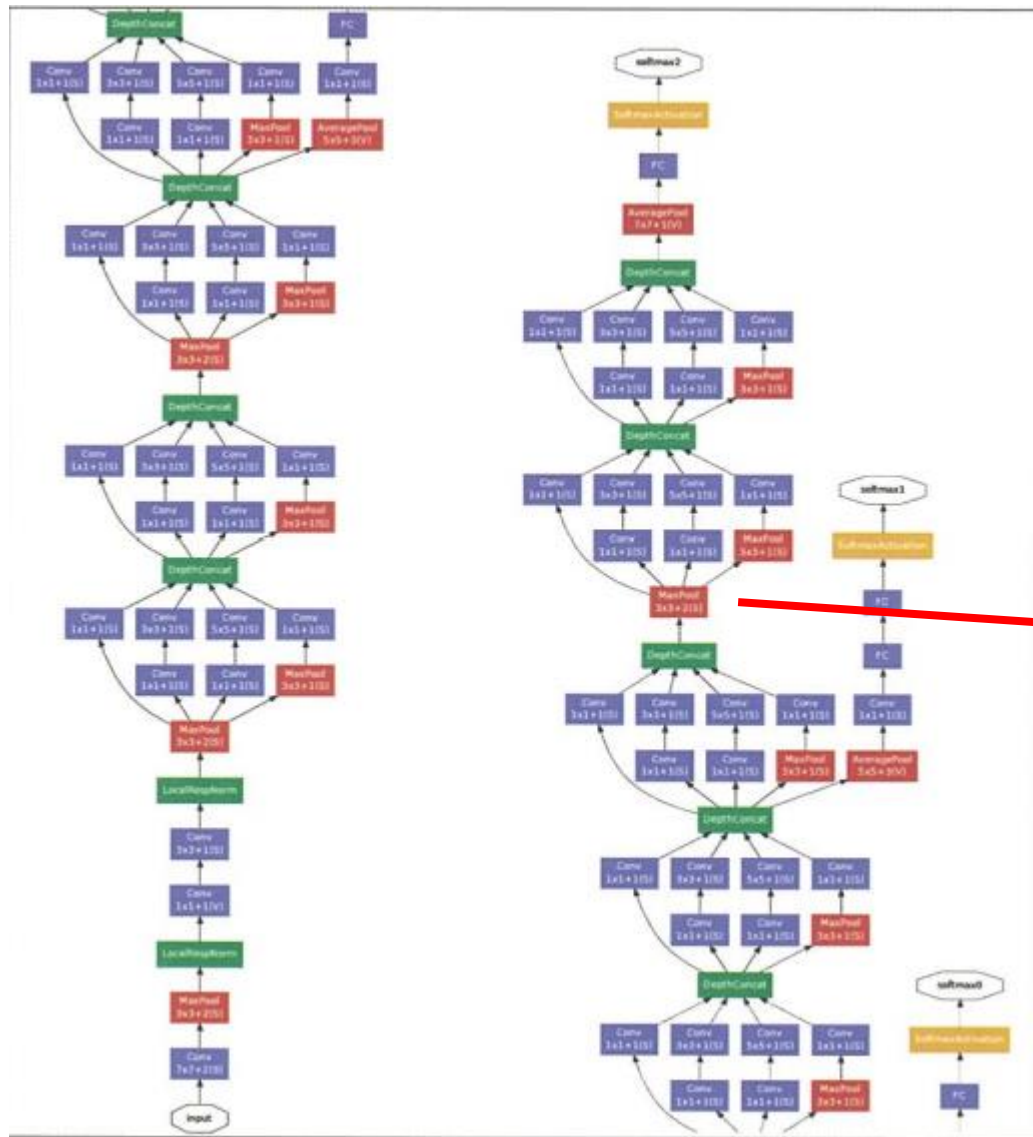
```
def conv_2_block(in_dim, out_dim):
    model = nn.Sequential(
        nn.Conv2d(in_dim, out_dim, kernel_size=3, padding=1),
        nn.ReLU(),
        nn.Conv2d(out_dim, out_dim, kernel_size=3, padding=1),
        nn.ReLU(),
        nn.MaxPool2d(2, 2)
    )
    return model
```

Convolution 연산 3번

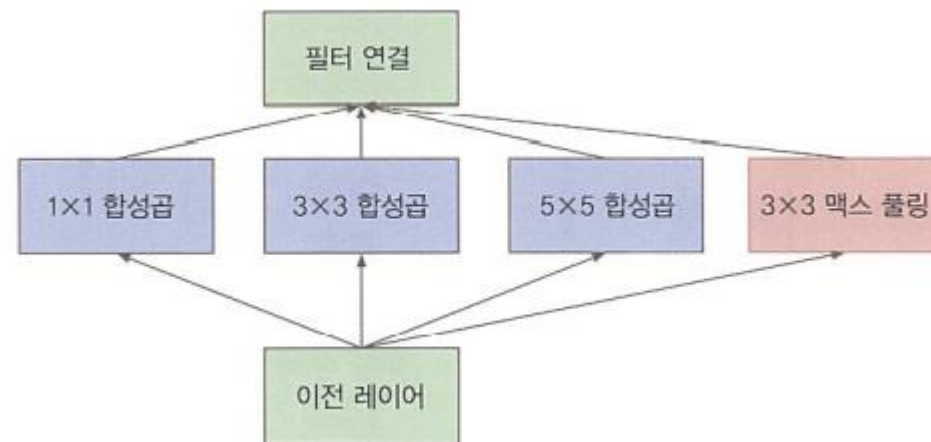
```
def conv_3_block(in_dim, out_dim):
    model = nn.Sequential(
        nn.Conv2d(in_dim, out_dim, kernel_size=3, padding=1),
        nn.ReLU(),
        nn.Conv2d(out_dim, out_dim, kernel_size=3, padding=1),
        nn.ReLU(),
        nn.Conv2d(out_dim, out_dim, kernel_size=3, padding=1),
        nn.ReLU(),
        nn.MaxPool2d(2, 2)
    )
    return model
```

2-2. GoogLeNet

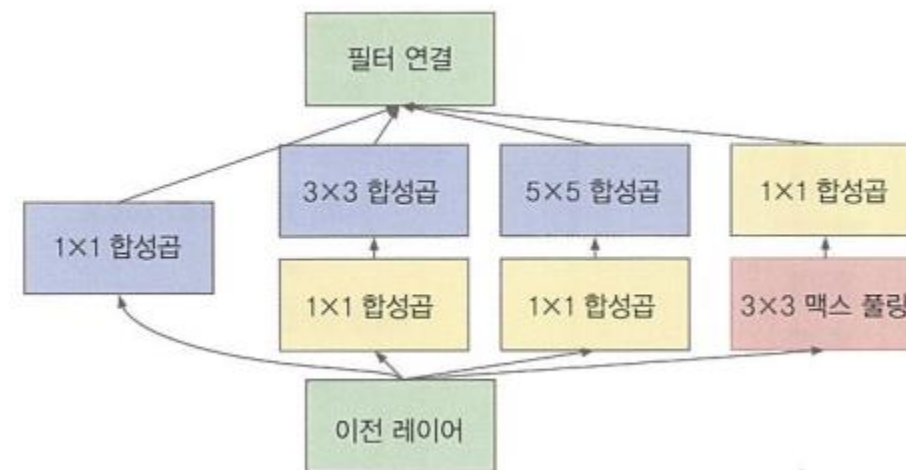
GoogLeNet Architecture



기초적인 Inception 모듈



차원 감소를 더한 Inception 모듈



2-2. GoogLeNet

Pytorch로 구현한 GoogLeNet Inception module

1x1 convolution

```
def conv_1(in_dim,out_dim):  
    model = nn.Sequential(  
        nn.Conv2d(in_dim,out_dim,1,1),  
        nn.ReLU(),  
    )  
    return model
```

1x1 Conv -> 3x3 Conv

```
def conv_1_3(in_dim,mid_dim,out_dim):  
    model = nn.Sequential(  
        nn.Conv2d(in_dim,mid_dim,1,1),  
        nn.ReLU(),  
        nn.Conv2d(mid_dim,out_dim,3,1,1),  
        nn.ReLU()  
    )  
    return model
```

1x1 Conv -> 5x5 Conv

```
def conv_1_5(in_dim,mid_dim,out_dim):  
    model = nn.Sequential(  
        nn.Conv2d(in_dim,mid_dim,1,1),  
        nn.ReLU(),  
        nn.Conv2d(mid_dim,out_dim,5,1,2),  
        nn.ReLU()  
    )  
    return model
```

3x3 max pooling -> 1x1 Conv

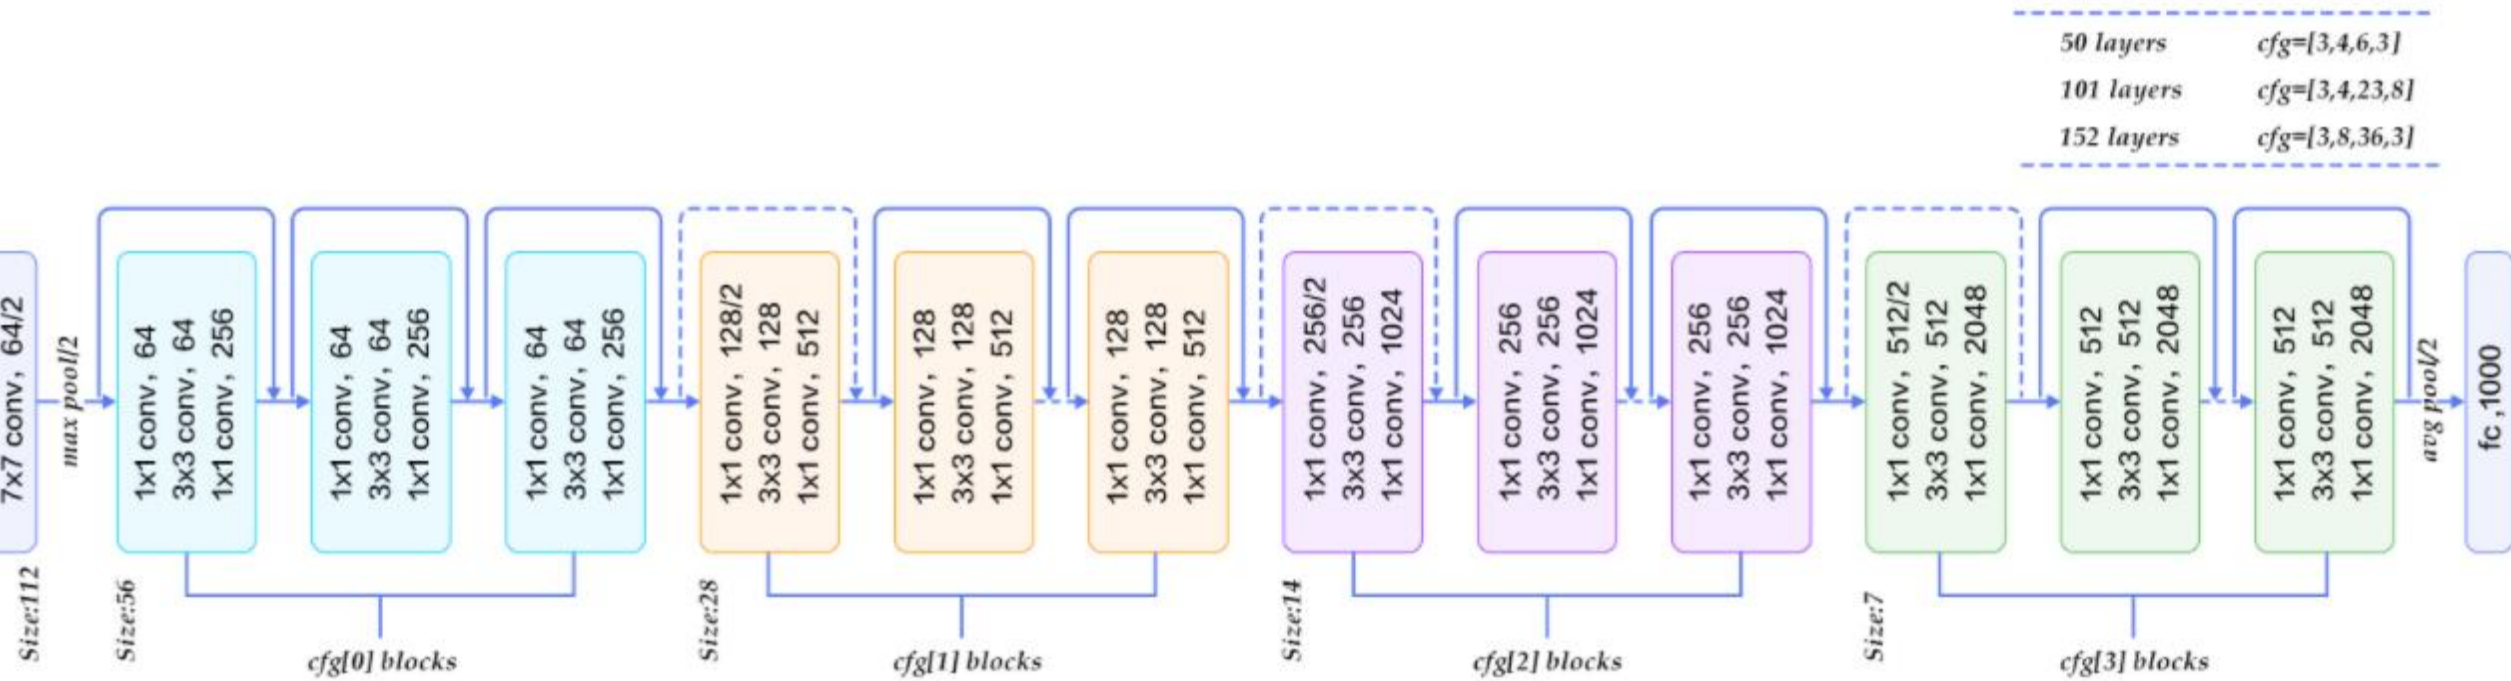
```
def max_3_1(in_dim,out_dim):  
    model = nn.Sequential(  
        nn.MaxPool2d(3,1,1),  
        nn.Conv2d(in_dim,out_dim,1,1),  
        nn.ReLU(),  
    )  
    return model
```

Inception Module

```
class inception_module(nn.Module):  
    def __init__(self,in_dim,out_dim_1,mid_dim_3,out_dim_3,mid_dim_5,out_dim_5,pool):  
        super(inception_module,self).__init__()  
        self.conv_1 = conv_1(in_dim,out_dim_1)  
        self.conv_1_3 = conv_1_3(in_dim,mid_dim_3,out_dim_3)  
        self.conv_1_5 = conv_1_5(in_dim,mid_dim_5,out_dim_5)  
        self.max_3_1 = max_3_1(in_dim,pool)  
  
    def forward(self,x):  
        out_1 = self.conv_1(x)  
        out_2 = self.conv_1_3(x)  
        out_3 = self.conv_1_5(x)  
        out_4 = self.max_3_1(x)  
        output = torch.cat([out_1,out_2,out_3,out_4],1)  
        return output
```



2-3. ResNet

ResNet Architecture





2-3. ResNet

잔차 학습 블록



이전 단계의 특성 변형 x (단순 특성)
단순한 특성 + 복잡한 특성 모두 사용

BottleNeck



GoogleNet의 아이디어 차용

2-3. ResNet

Pytorch로 구현한 Bottleneck

```
class Bottleneck(nn.Module):
    def __init__(self, in_dim, mid_dim, out_dim, act_fn, down=False):
        super(Bottleneck, self).__init__()
        self.down = down

        # 특성지도의 크기가 감소하는 경우
        if self.down:
            self.layer = nn.Sequential(
                conv_block_1(in_dim, mid_dim, act_fn, 2),
                conv_block_3(mid_dim, mid_dim, act_fn),
                conv_block_1(mid_dim, out_dim, act_fn),
            )
            self.downsample = nn.Conv2d(in_dim, out_dim, 1, 2)

        # 특성지도의 크기가 그대로인 경우
        else:
            self.layer = nn.Sequential(
                conv_block_1(in_dim, mid_dim, act_fn),
                conv_block_3(mid_dim, mid_dim, act_fn),
                conv_block_1(mid_dim, out_dim, act_fn),
            )

        # 더하기를 위해 차원을 맞춰주는 부분
        self.dim_equalizer = nn.Conv2d(in_dim, out_dim, kernel_size=1)
```

```
def forward(self, x):
    if self.down:
        downsample = self.downsample(x)
        out = self.layer(x)
        out = out + downsample
    else:
        out = self.layer(x)
        if x.size() is not out.size():
            x = self.dim_equalizer(x)
        out = out + x
    return out
```

Block을 통과했을 때 크기가 줄어드는지 여부

1x1 컨볼루션 -> 3x3 컨볼루션 -> 1x1 컨볼루션

Feature map이 감소할 때와 그대로일 때의 경우를 나눔

차원의 크기를 맞춰주는 부분


3. 딥러닝의 활용 및 미래

3-1-1. Object Detection

Object Detection

사물 검출 (ex. R-CNN, YOLO)

R-CNN



YOLO

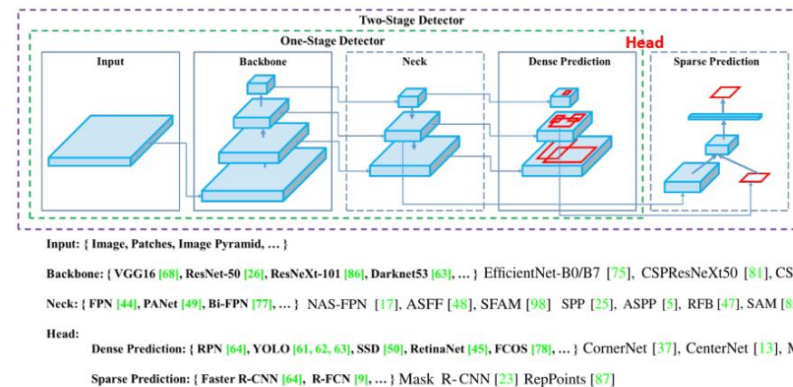


Figure 2: Object detector.

4-1-1. Object Detection

YOLOv5를 이용한 드론에서의 객체 검출



YOLOv5를 이용한 마스크 헬멧 검사




마스크 및 헬멧 인식

4-1-2. Segmentation

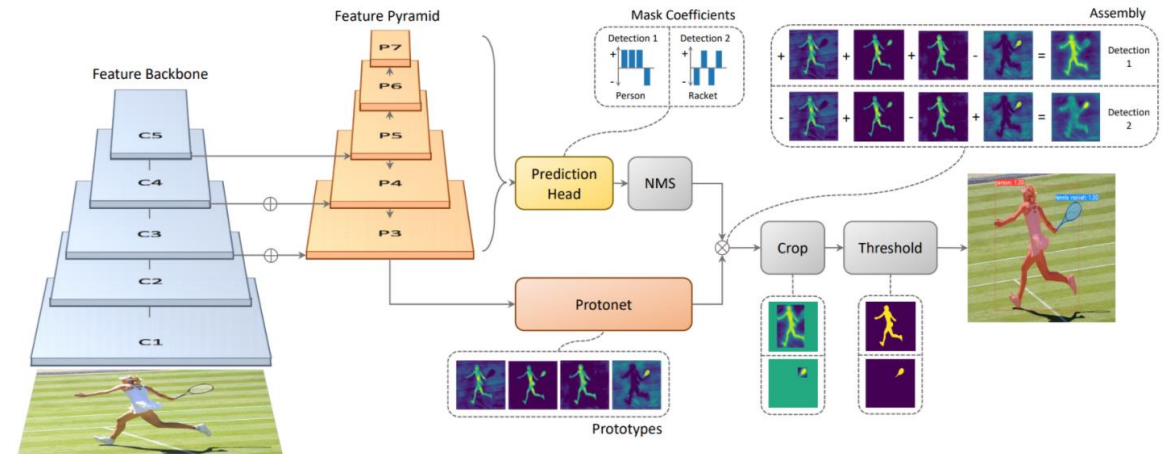
Image Segmentation

이미지를 픽셀 수준에서 분할

Fully-Convolution-Network



YOLOACT



4-1-2. Segmentation

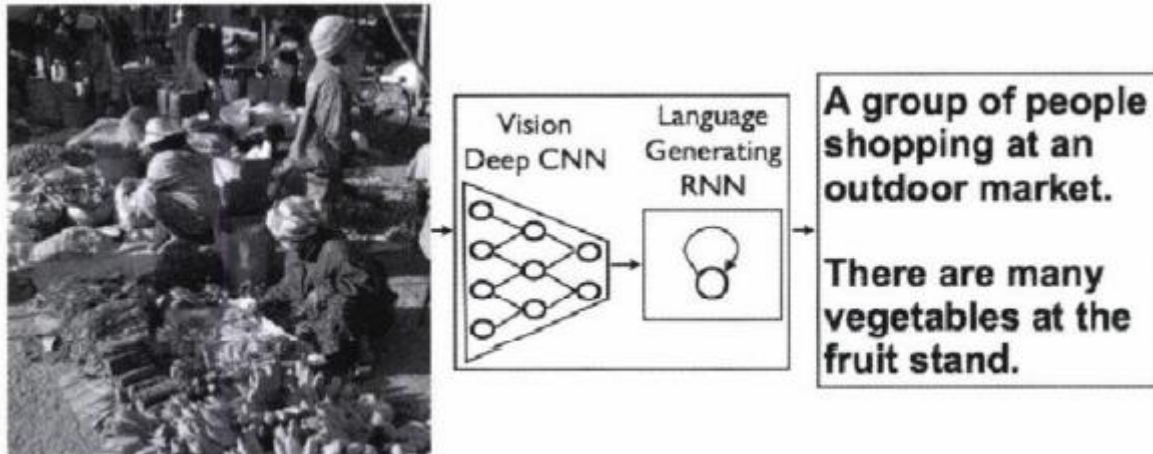
Detectron2를 활용한 Image Segmentation



4-1-2. 사진 캡션 생성

사진 캡션 생성

NIC(Neural Image Caption)



CNN + RNN(LSTM)


Encoder = CNN \Rightarrow Decoder = RNN

4-2-1. Image Generation

Image Generation

이미지를 생성하는 기술

DCGAN(Deep Convolution Generative Adversarial Network)

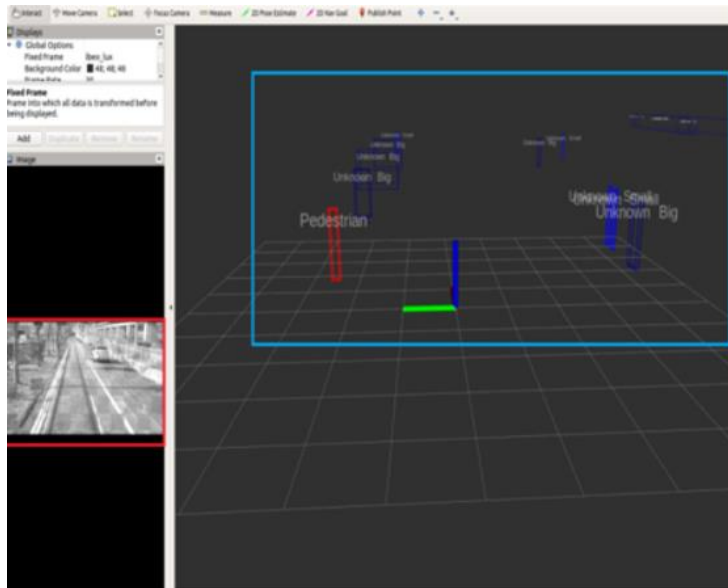


Fully Connected를 CNN 구조로 대체
(기존 GAN과의 큰 차이점)

4-2-2. 자율주행

Self - Driving

Lidar, Rader, IMU, Camera 등을 이용하여 운전자 없이 자율 주행을 이뤄냄



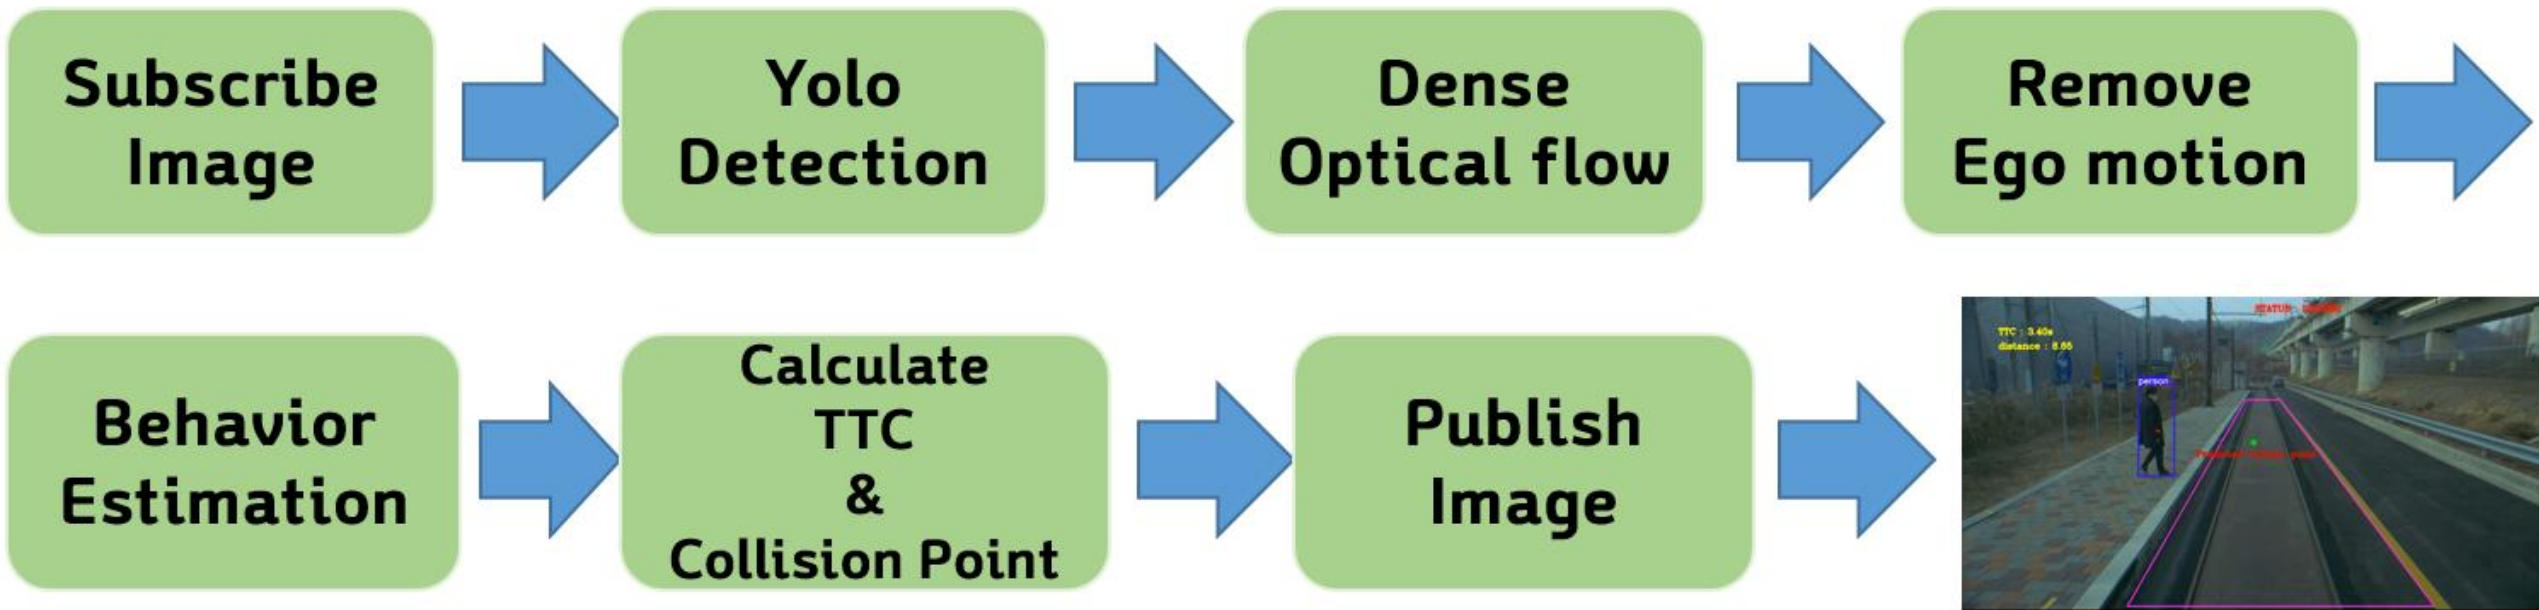
Lidar를 이용한 객체 인식



객체 인식 및 충돌 시간 및 지점 예측

4-2-2. 자율주행

Flow chart



4-2-3. 강화학습

Reinforcement Learning

컴퓨터에게도 시행착오를 겪게 하면서 스스로 학습하게 함

